



Duração: 20 minutos

Objetivo

Esta seção fornece um resumo das principais ferramentas de código aberto para Ciência de Dados abordadas nos vídeos da Parte 1 e Parte 2 deste curso.

Elas são implementadas classificadas como -

- **Ferramentas de Gerenciamento de Dados** - Facilita o armazenamento, organização e recuperação de dados. Inclui Banco de Dados Relacionais, Banco de Dados NoSQL, e plataformas de Big Data.
- **Ferramentas de Integração e Transformação de Dados** - Otimiza pipelines de dados e automatiza fluxos de trabalho de processamento de dados. A tarefa de integração e transformação de dados no mundo clássico de data warehousing é Extra, Transformar e Carregar (ETL).
- **Ferramentas de Visualização de Dados** - Fornece representações gráficas de dados e ajuda na comunicação de insights.
- **Ferramentas de Implantação, Monitoramento e Avaliação de Modelos** - Suporta construção, implantação, monitoramento e avaliação de dados e modelos de aprendizagem de máquina.
- **Ferramentas de Gerenciamento de Ativos de Dados** - Organiza e gerencia dados, impõe controles de acesso e garante backups de ativos.
- **Ferramentas de Desenvolvimento e Execução de Código** - Fornece ambientes para desenvolver, testar e implantar código, oferecendo recursos computacionais para executar-lo.
- **Ferramentas de Gerenciamento de Ativos de Código** - Permite o armazenamento e gerenciamento de código, rastreia alterações e apoiar o desenvolvimento colaborativo.

Ferramentas de Gerenciamento de Dados

MySQL

- Sistema de gerenciamento de banco de dados relacional (RDBMS) de código aberto popular
- Utiliza a linguagem de consulta estruturada (SQL) para gerenciar e consultar dados.
- Uso comum:
 - Aplicações web
 - Armazenamento de dados
 - Comércio eletrônico

PostgreSQL

- Sistema de gerenciamento de banco de dados relacional (RDBMS) poderoso e de código aberto
- Enfatiza a extensibilidade e a conformidade com SQL.
- Oferece recursos avançados, como:
 - Suporte a JSON
 - Pesquisa de texto completo
 - Dados espaciais

Apache CouchDB

- Banco de dados NoSQL orientado a documentos
- Usa JSON para armazenar dados
- Almacenamento escalável
- Tolerante a falhas
- Fácil de usar

MongoDB

- Banco de dados NoSQL orientado a documentos
- Armazena dados em um JSON flexível
- Oferece:
 - Escalabilidade
 - Alta disponibilidade
 - Distribuição de dados
- Adequado para aplicações web modernas que lidam com grandes volumes de dados não estruturados

Apache Cassandra

- Banco de dados NoSQL orientado a documentos, altamente escalável e distribuído
- Pode lidar com grandes quantidades de dados estruturados e não estruturados em muitos servidores comuns.
- Oferece:
 - Alta disponibilidade
 - Tolerância a falhas
 - Níveis de consistência ajustáveis
- Adequado para aplicações críticas de missão

Sistema de Arquivos Distribuído Hadoop (HDFS)

- Projetado para trabalhar com grandes conjuntos de dados como o Apache Hadoop em um ambiente de computação distribuída
- Processamento de dados de alto taxa de transferência no nível análogo em blocos (padrão de 128MB), e osso bloco são distribuídos entre vários DataNodes
- Os dados são replicados em diferentes DataNodes, garantindo alta disponibilidade e tolerância a falhas
- Escalável e eficiente

Ceph

- Plataforma de armazenamento definida por software, pronta e de código aberto, adequada para ambientes de nuvem híbrida
- Projetado para data centers modernos
- Fornece um sistema de armazenamento unificado, altamente escalável, que pode ser usado para armazenamento de objetos (como AWS S3), armazenamento em bloco (como discos virtuais para VMs) e armazenamento de arquivos (como NFS) sob um único sistema unificado
- Alto desempenho, disponibilidade e confiabilidade

Elasticsearch

- Principal ferramenta de busca e análise distribuída e RESTful
- Baseado na biblioteca Lucene
- Banco de texto completo, análise de dados em tempo real
- Almacenamento escalável
- Fácil de usar
- Poderosas capacidades de consulta
- Indexação de dados em tempo real para recuperação rápida de documentos.

Ferramentas de Integração e Transformação de Dados

Apache Airflow

- Plataforma de código aberto para autorar, agendar e monitorar fluxos de trabalho de forma programática
- Criação originadamente pelo Airbnb
- Permite que os usuários definam e executem fluxos de trabalho complexos
- Suporte para:
 - Dependências de tarefas
 - Parallelism
 - Tratamento de erros

Kubernetes

- Um kit de ferramentas de aprendizado de máquina de código aberto que permite a execução de pipelines de ciência de dados sobre o Kubernetes.
- Fornece uma plataforma para construir, implantar e gerenciar fluxos de trabalho de aprendizagem de máquina de ponta a ponta em grande escala
- Suporte para:
 - Treinamento distribuído
 - Serviço modelos
 - Agentes de hyperparameter

Apache Kafka

- Plataforma de streaming distribuída que permite que aplicativos publiquem, processem e assistem fluxos de registros em tempo real
- Criado originadamente no LinkedIn
- Escalável, tolerante a falhas e de alto desempenho
- Adequado para construir aplicações críticas e intensivas em dados

Apache Nifi

- Uma plataforma de integração de dados de código aberto que permite aos usuários automatizar o fluxo de dados entre sistemas
- Fornece uma interface de usuário baseada na web para preparar e gerenciar fluxos de dados
- Suporte para:
 - Roteamento de dados
 - Transformação
 - Enriquecimento
 - Entre outros capacidades

Apache Spark SQL

- Uma máquina no ecossistema Spark que fornece uma interface de programação para trabalhar com dados estruturados usando:
 - SQL
 - Data frames
 - DataSets
- Suporta uma ampla gama de fontes de dados e oferece desempenho otimizado para tarefas complexas de processamento de dados.

Nube-RED

- Uma ferramenta de programação visual de código aberto para conectar dispositivos de hardware, APIs e serviços online
- Permite que os usuários criem fluxos de mensagens automáticas por eventos
- Baixo consumo de recursos, a ponto de rodar em um dispositivo pequeno como um Raspberry Pi.
- Suporte para:
 - Transformação de dados
 - Filtragem
 - Agrupação

Ferramentas de Visualização de Dados

FvickBust

- Biblioteca de código aberto para criar visualizações de dados interativas e exploratórias em Python e notebooks Jupyter
- Fornece uma variedade de visualizações integradas a conjuntos de dados
- Suporte para personalização e extensibilidade, acesso de bibliotecas de terceiros

Hue

- Interface web de código aberto para analisar e visualizar grandes conjuntos de dados no Apache Hadoop
- Oferece uma experiência amigável para explorar dados e criar visualizações
- Não é necessário ter habilidades de programação e permitir criar visualizações a partir de consultas SQL

Kibana

- Ferramenta de visualização de dados de código aberto que permite aos usuários integrar com seus dados através de uma interface baseada na web
- Comumente usada com Elasticsearch para analisar e visualizar grandes conjuntos de dados

Apache Superset

- Uma aplicação web moderna de inteligência empresarial pronta para empresas que facilita a visualização e exploração de grandes conjuntos de dados
- Oferece um rico conjunto de opções de visualização de dados, incluindo:
 - Gráficos
 - Tabelas
 - Mapas
 - Análise geoespacial
 - Processamento de dados em tempo real

Ferramentas de Implantação de Modelos

Apache PredictionIO

- Serviço de aprendizagem de máquina de código aberto construído em uma infraestrutura escalável e distribuída
- Permite que os desenvolvedores construam, avaliem e implantem rapidamente modelos preditivos para vários casos de uso, como:
 - Recomendação
 - Classificação
 - Agrupamento

Kubernetes

- Plataforma de código aberto para orquestração de contêineres
- Larga escala e gerencia automaticamente aplicações em contêineres
- Oferecendo recursos como:
 - Escalamento automático
 - Auto-recuperação
 - Balanceamento de carga
- Permite a gestão e orquestração de contêineres em diversos hosts

Apache Seldon

- Plataforma de código aberto para implantar e gerenciar modelos de aprendizagem de máquina no Kubernetes
- Fornece uma maneira de:
 - Serviço modelos em grande escala
 - Automatizar fluxos de trabalho de implantação de modelos
 - Monitorar o desempenho dos modelos implantados em tempo real

ML.eap

- Biblioteca de código aberto para serializar e deserializar modelos de aprendizagem em um ambiente multiplataforma
- Oferece aos usuários a capacidade de exportar modelos de diferentes bibliotecas e frameworks de aprendizagem de máquina, como:
 - Spark
 - Scikit-learn
 - TensorFlow
- Implementa-se em ambientes de produção de alta capacidade e baixa latência

TensorFlow Lite

- Ferramenta de código aberto para executar modelos de aprendizagem de máquina em dispositivos móveis e embarcados
- Permite inferência eficaz em plataformas móveis e embarcadas
- Suporta uma variedade de aceleradores de hardware, como:
 - CPUs
 - GPUs
 - ASICs personalizadas

Red Hat OpenShift

- Framework de aplicação em contêiner baseado em Kubernetes
- Com características como: escalabilidade e segurança
- Oferece um método para criar, implantar e gerenciar aplicações em contêineres

TensorFlow Serving

- Utilitário de código aberto que serve modelos de aprendizado de máquina em ambientes do mundo real
- Suporta interfaces HTTP e gRPC para servir previsões
- Oferece alta escalabilidade e implantação e gerenciamento de modelos TensorFlow com baixa latência

TensorFlow.js

- Biblioteca de código aberto para construir e implantar modelos de aprendizado de máquina em JavaScript
- Permite treinar e executar modelos diretamente no navegador ou no Node.js
- Suporta uma ampla gama de arquiteturas de modelos, incluindo redes neurais, árvores de decisão e k-vizinhos mais próximos

Ferramentas de Monitoramento e Avaliação de Modelos

ModelDB

- Plataforma de código aberto para gerenciar modelos de aprendizado de máquina e experimentos
- Oferece uma maneira de rastrear e reproduzir experimentos, versionar modelos e colaborar com membros da equipe

PractiChen

- Sistema de monitoramento dispositivo gratuitamente que coleta e armazena métricas em tempo real de diferentes fontes
- Permite visualizar e definir alertas sobre a saúde e o desempenho de contêiner e aplicativos
- Suporta uma variedade de protocolos de coleta de dados, como endpoints HTTP, esportes e agentes

IBM AI Fairness 360

- Conjunto de ferramentas de código aberto para detectar e mitigar viés em modelos de aprendizado de máquina
- Fornece uma maneira de medir a justiça e o viés dos modelos, bem como um conjunto de algoritmos para mitigar o viés e criar modelos mais justos

IBM AI Explainability 360

- Conjunto de ferramentas de código aberto para explicar o comportamento e as decisões de modelos de aprendizado de máquina
- Oferece uma maneira de medir a explicabilidade e a interpretabilidade dos modelos, bem como um conjunto de algoritmos para gerar explicações e visualizações do comportamento do modelo

IBM Adversarial Robustness 360 Toolkits

- Biblioteca gratuita e de código aberto para proteger modelos de aprendizado de máquina contra ataques adversários
- Inclui um método para medir a robustez e a vulnerabilidade do modelo
- Inclui um conjunto de algoritmos para melhorar a robustez do modelo e detectar exemplos adversários

Ferramentas de Desenvolvimento e Execução de Código

Jupyter IDE

- Editor de código aberto
 - Suporte:
 - Julia
 - Python
 - Desenvolvimento em R com Jupyter Notebook
 - JupyterLab
 - JupyterLabUI
 - Crie e compartilhe documentos contendo:
 - Código ao vivo
 - Equipes
 - Visualizações
 - Texto narrativo
 - JupyterLab inclui:
 - Oportunidade personalizada de cadastros
 - JupyterLab estende todas essas capacidades para a empresa

RStudio

- Para desenvolvedores
- IDE gratuito e de código aberto
- Criado para gerenciar e executar código R
- Funciona em todas as plataformas
 - Inclui:
 - Controle de versão
 - Capacidade de gerenciamento de projetos

Microsoft Visual Studio

- Um IDE que suporta uma variedade de linguagens de programação, incluindo:
 - C
 - C++
 - C++/CLI
 - Visual Basic.NET
 - C#
 - F#
 - JavaScript
 - TypeScript
 - XML
 - XSLT
 - HTML
 - CSS
- Usando plug-ins, suporta:
 - Python
 - Ruby
 - Node.js
 - M
 - Outras linguagens

PyCharm

- Principalmente um ambiente IDE baseado em assinatura
- Oferece mais de 16 ferramentas dedicadas para assistência em configuração, testes e desenvolvimento web
- Suporta desenvolvimento científico com integração IPython e suporte a Matplotlib e NumPy
- Também oferece um IDE gratuito baseado na comunidade e de código aberto, com capacidades limitadas

Spyder

- IDE gratuito e de código aberto baseada em Python, projetada por e para cientistas, engenheiros e analistas de dados
- Apresenta uma combinação única de ferramentas de desenvolvimento abrangentes para:
 - Edição avançada
 - Análise
 - Depuração
 - Profiling
 - Capacidades de visualização

Anacanda Navigator

- Navegador baseado em GUI de código aberto que suporta o desenvolvimento em Python e se integra com:
 - Eclipse e PyDev
 - IDLE
 - IntelliJ
 - Microsoft Visual Studio Code (VS Code)
 - NetBeans IDE
 - PyCharm
 - Python para Visual Studio Code
 - Ferramenta Python para Visual Studio (PTVS)
 - Spyder
 - Sublime Text
 - Wing IDE

Ferramentas de Gerenciamento de Ativos de Código

Git

- Sistema de controle de versão de código aberto para gerenciamento de alterações no código e colaboração entre desenvolvedores
- Fornece uma maneira de gerenciar e organizar alterações no código, colaborar no desenvolvimento de código e manter um histórico de revisões de código

GitLab

- Gerenciador de repositório Git baseado na web
- Fornece uma plataforma DevOps completa para:
 - Gerenciamento de código fonte
 - Integração e implantação contínuas
 - Monitoramento
- Permite que as equipes colaborem em:
 - Desenvolvimento de código
 - Automação processos de construção e implantação
 - Rastrear métricas e desempenho ao longo de todo o ciclo de vida do desenvolvimento de software

GitHub

- Serviço de hospedagem de repositórios Git baseado na web que fornece uma plataforma para desenvolvedores colaborarem em código e gerenciar projetos de software
- Permite que os usuários:
 - Criem, façam fork e contribuam para projetos de código aberto
 - Rastrem alterações no código
 - Gerenciem problemas
 - Solicitem de pull
- **Biblioteca do Atlassian**
 - Serviço de hospedagem de repositórios Git baseado na web
 - Fornece uma plataforma para desenvolvedores colaborarem em código e gerenciar projetos de software, com recursos como:
 - Pull requests
 - Revisão de código
 - Permissões de branch

Antier(r)

Shipix GitHub



Skills Network

